

Insurance DWH & Performance Tuning

Dự án cá nhân — Data Engineering trên nền tảng Microsoft SQL Server, ứng dụng dữ liệu bảo hiểm thật, kèm lớp phân tích Power BI

1. Mục tiêu & Bối cảnh

Dự án được thiết kế bám sát JD vị trí Data Engineer tại Amaris Consulting, phục vụ khách hàng ngành Bảo hiểm nhân thọ dùng hệ sinh thái Microsoft (SQL Server, T-SQL, SSIS). Trọng tâm là chứng minh năng lực thiết kế Data Warehouse chuẩn mực, viết ETL bằng T-SQL, và đặc biệt là **Performance Tuning** — phân tích execution plan, indexing, tối ưu truy vấn trên dữ liệu lớn thật.

Điểm khác biệt so với các dự án portfolio thông thường: dùng **dữ liệu thật, có sẵn công khai** thay vì dữ liệu giả lập, và bổ sung lớp Power BI với insight thật sự — thể hiện thêm góc nhìn phân tích (analyst) bên cạnh kỹ năng kỹ thuật (engineer).

2. Nguồn dữ liệu thật

Bộ dữ liệu	Quy mô	Vai trò trong dự án
Brazilian Insurance Market Data (SUSEP — cơ quan quản lý bảo hiểm Brazil)	~8.3 triệu dòng, dữ liệu thật từ 2003, cập nhật theo quý	Nguồn chính cho Fact_Premium / Fact_Claims — phí, bồi thường theo công ty, sản phẩm, bang, tháng
Prudential Life Insurance Assessment (Kaggle)	~60 nghìn dòng, dữ liệu thật từ cuộc thi underwriting	Nguồn cho Dim_Customer — đặc điểm nghiệp vụ thật (tuổi, BMI, tiền sử y tế đã mã hoá, mức rủi ro)

Hai bộ dữ liệu được kết hợp: SUSEP cung cấp khối lượng giao dịch đủ lớn để tuning thật, Prudential cung cấp chiều khách hàng có ý nghĩa nghiệp vụ thật (không phải random).

3. Kiến trúc tổng thể

Dữ liệu thô (CSV thật) → Staging trong SQL Server → Data Warehouse dạng Star Schema → Tối ưu hoá truy vấn (indexing, execution plan) → Trực quan hoá & insight trên Power BI.

- Staging:** nạp CSV thô bằng BULK INSERT, giữ nguyên cấu trúc gốc để đối chiếu.
- Schema Migration:** mọi thay đổi cấu trúc DWH quản lý bằng công cụ migration (Flyway/DbUp), có version, review và rollback được — không chạy tay ALTER TABLE.
- Data Warehouse (Star Schema):** Fact_Premium, Fact_Claims (bảng sự kiện); Dim_Customer (SCD Type 2), Dim_Policy, Dim_Date, Dim_Region (bảng chiều).

- **ETL & Incremental Load:** T-SQL Stored Procedures dùng lệnh MERGE để UPSERT; bật SQL Server Change Data Capture (CDC) trên Staging để chỉ nạp phần dữ liệu mới/thay đổi, không reload toàn bộ mỗi lần.
- **Audit Log & Idempotency:** mỗi lần chạy ETL được ghi log (batch, thời gian, số dòng, trạng thái); chạy lại cùng batch không tạo dữ liệu trùng.
- **Data Quality Framework:** bộ kiểm định tự động (not null, unique, referential integrity) chạy như một bước trong pipeline, làm pipeline dừng & cảnh báo nếu không đạt.
- **Orchestration:** Apache Airflow (chạy trong Docker) điều phối toàn bộ DAG — Load Staging → Load Dim → Load Fact → Data Quality Check — có retry và cảnh báo khi lỗi.
- **Performance Tuning:** đo trước/sau bằng Execution Plan + STATISTICS IO/TIME, thêm Non-Clustered/Covering Index, cân nhắc partitioning theo tháng.
- **Analytics:** Power BI kết nối trực tiếp DWH, xây dashboard loss ratio, xu hướng phí, phát hiện outlier theo bang/sản phẩm bảo hiểm.

4. Công nghệ sử dụng

Hạng mục	Công cụ
Cơ sở dữ liệu	Microsoft SQL Server (Docker trên WSL)
Ngôn ngữ chính	T-SQL (ETL, tuning), Python (nạp dữ liệu, DAG Airflow)
Incremental Load	SQL Server Change Data Capture (CDC)
Orchestration	Apache Airflow (chạy trong Docker)
Schema Migration	Flyway hoặc DbUp — quản lý schema theo version
Data Quality	dbt tests / Great Expectations — kiểm định tự động trong pipeline
Công cụ quản trị DB	Azure Data Studio / SSMS
Trực quan hoá	Power BI Desktop
Quản lý mã nguồn & tài liệu	Git/GitHub, README có ảnh chụp Execution Plan

5. Lộ trình 8 giai đoạn

Giai đoạn 1 — Khảo sát & chuẩn bị dữ liệu thật

Tải bộ SUSEP và Prudential, khảo sát schema gốc, chất lượng dữ liệu, lập kế hoạch mapping sang mô hình đích.

Giai đoạn 2 — Hạ tầng & Staging

Dựng SQL Server + Airflow bằng Docker Compose, tạo database Staging, nạp CSV thô bằng BULK INSERT.

Giai đoạn 3 — Thiết kế Data Warehouse & Schema Migration

Thiết kế Star Schema (Fact_Premium, Fact_Claims, Dim_Customer SCD Type 2, Dim_Policy, Dim_Date, Dim_Region). Quản lý toàn bộ script tạo/sửa schema bằng công cụ migration (Flyway/DbUp).

Giai đoạn 4 — ETL bằng T-SQL với Incremental Load & Audit Log

Viết Stored Procedures dùng MERGE để UPSERT; bật CDC trên Staging để chỉ nạp phần thay đổi; ghi log mỗi lần chạy (batch, số dòng, trạng thái) và đảm bảo idempotent khi chạy lại.

Giai đoạn 5 — Data Quality Framework

Định nghĩa bộ kiểm định tự động (not null, unique, referential integrity) chạy như một bước trong pipeline; log kết quả pass/fail, cảnh báo khi check quan trọng thất bại.

Giai đoạn 6 — Orchestration với Airflow

Định nghĩa DAG Airflow: Load Staging → Load Dim (song song) → Load Fact → Data Quality Check → Notify; cấu hình retry và cảnh báo khi task lỗi.

Giai đoạn 7 — Performance Tuning & Tài liệu hoá

Đo Execution Plan/STATISTICS IO trước khi có index, thêm Non-Clustered/Covering Index, đo lại, so sánh, viết README.

Giai đoạn 8 — Power BI & Insight

Kết nối Power BI với DWH, xây dashboard loss ratio, xu hướng phí theo thời gian/bang/sản phẩm, viết nhận định phân tích.

Chi tiết từng bước thực hiện (checklist, script tham khảo, tiêu chí hoàn thành) được trình bày trong file đồng hành: **implementation-guide.md**.